

# AADS LLM 파인튜닝용 QA 데이터셋 구축: 규제와 거버넌스 (국내)

- 작성일: 2025년 12월 01일
- 기획: (주)페블러스 데이터 커뮤니케이션팀
- 인터랙티브 콘텐츠: <https://blog.pebbrous.ai/>

## I. 서론: 보고서 목적 및 AADS-LLM의 전략적 역할

본 보고서는 **AADS (Agentic AI Data Scientist) LLM**의 성공적인 구축을 위한 핵심 전략 중 하나인 규제와 거버넌스 도메인 특화 QA (질의응답) 데이터셋의 구성 및 상세 내용을 제시하는 것을 목적으로 합니다.

### 1. AADS-LLM의 핵심 역할 정의

AADS LLM은 단순한 도메인 전문가 역할을 넘어, 데이터의 생성부터 폐기까지 전 과정의 신뢰성을 보증하는 데이터 감사관 역할을 통합하여 수행하도록 설계되었습니다. 이러한 이중적 정체성(Dual Identity)을 통해 고객에게 진정한 의미의 **AI Ready** 데이터를 약속하는 핵심 기술 해자(Core Technological Moat)를 구축합니다.

이를 실현하기 위해 당사는 **한국과학기술정보연구원(KISTI)**과 협력하여, 과학기술 분야 특화 모델인 **KONI LLM**을 기반으로 데이터 품질 관리에 최적화된 AADS LLM을 공동 개발하고 있습니다.

### 2. 규제와 거버넌스 도메인의 중요성

LLM이 데이터 감사관 역할을 수행하기 위해서는 데이터 과학 이론, 품질 표준과 더불어, 데이터 및 AI 활용에 대한 국내외 규제 및 법적 환경에 대한 깊이 있는 지식이 필수적입니다. 특히 규제와 거버넌스 카테고리의 문서들(예: EU AI Act 원문, GDPR, 국내 AI 기본법 등)은 LLM에게 규제 지식을 주입하는 학습 자료로서 기능합니다.

## II. QA 데이터셋 구축 전략 및 방법론

AADS LLM의 다면적 능력을 효과적으로 학습시키기 위해, QA 데이터셋은 명확한 설계 철학에 기반한

다층적 포트폴리오로 구축되었습니다.

## 1. QA 생성 방법론: 4가지 핵심 질의 유형

본 프로젝트는 LLM이 특정 도메인 데이터를 단순 암기하는 것을 넘어, 문서의 여러 측면을 깊이 있게 탐색하고 맥락에 맞게 추론하도록 유도하기 위해 질의를 네 가지 핵심 유형으로 분류하여 생성했습니다.

유형 코드	유형명	정의 (학습 목표)
A	도메인 정의/목적	데이터셋의 구축 목적, 활용 분야, 해결하고자 하는 문제 등 프로젝트의 근본적인 '왜(Why)'에 해당하는 정보를 질의합니다.
B	데이터 구조/구성	데이터의 종류, 형식, 수량, 분포, 메타데이터 구조 등 데이터셋의 구체적인 '무엇(What)'에 해당하는 정보를 질의합니다.
C	AI 모델/임무	데이터를 활용하여 수행할 AI 임무(Task), 적용 모델, 알고리즘, 성능 목표 등 '어떻게(How)'에 해당하는 정보를 질의합니다.
D	품질/공정 관리	데이터 수집, 정제, 가공(라벨링) 기준, 검수 절차 및 품질 관리 지표 등 데이터 구축 과정의 신뢰성에 관한 정보를 질의합니다.

## 2. 규제와 거버넌스 도메인 소스 구성

'규제와 거버넌스' 카테고리에는 총 61개의 문서가 포함되어 있으며, 이 중 국내 규제 법제는 총 40개의 문서를 기반으로 8개의 세부 분류(Folder L3)로 나뉘어 QA 데이터셋이 생성되었습니다.

### Folder L3 분류 분포:

- 공공데이터 관리 (20개): 행정기관의 데이터 거버넌스 및 품질 관리 지침.
- 교육 및 학교 (11개): 교육 분야 AI 윤리 원칙 및 지역 교육청 조례.
- AI 기본법 (4개): AI 관련 국내 기본 법안 및 제정 동향.
- 데이터 산업법 (2개): 데이터 산업 진흥 관련 법률 및 시행령.
- AI 법제 및 윤리, AI 이용자 보호, 저작권 및 법제, 정보화 (각 1개): 개별적인 윤리 원칙 및 행정 규정.

## III. 규제와 거버넌스 QA 데이터셋 상세 목록 (국내 규제 법제)

페블러스에서 수집한 국내 AI/데이터 규제 및 거버넌스 관련 소스 문서에 따라, 국내 규제 법제 8개 그룹

에 대해 4가지 유형의 질의응답 쌍 32개를 아래와 같이 제시합니다.

## 1. AI 기본법 (AI 기본법)

유형코드	유형명	질문 (Question)	답변 (Answer)
A	도메인 정의/목적	인공지능 발전과 신뢰 기반 조성 등에 관한 기본법(AI 기본법)의 하위 법령을 마련하는 주된 목적은 무엇입니까?	하위 법령은 법률에서 정한 투명성, 안전성 확보 의무 및 고영향 AI 사업자 책무 등을 구체화하고 명확화하여, 기업의 규제 우려와 불확실성을 완화하는 데 주력합니다.
B	데이터 구조/구성	AI 기본법 하위 법령 마련을 위해 추진되는 7가지 가이드라인 중 세 가지만 예시로 들어주십시오.	주요 가이드라인으로는 '고영향 기준 예시 가이드', 'AI 안전성 확보 의무 고시 및 가이드', 그리고 'AI 투명성 확보 가이드' 등이 마련될 예정입니다.
C	AI 모델/임무	AI 기본법 시행령 초안에 따라 생성형 AI 이용자에 대한 투명성 의무(사전 고지 및 결과물 표시)가 면제될 수 있는 두 가지 경우는 무엇입니까?	투명성 의무는 해당 AI가 사업자의 내부 업무용 이거나, 생성형 AI 기반임이 명백한 경우에 면제될 수 있습니다.
D	품질/공정 관리	과기정통부가 AI 기본법 하위 법령 초안을 마련하는 과정에서 이해관계자로부터 의견 수렴을 얼마나 진행했습니까?	하위 법령 초안은 민간 전문가 80여 명으로 구성된 하위법령 정비단 전체 회의 및 워킹그룹별 회의와 더불어, 산업계, 시민단체, 관계 부처 등으로부터 총 74회에 걸친 의견 수렴 및 검토를 거쳤습니다.

## 2. 데이터 산업법 (데이터 산업법)

유형코드	유형명	질문 (Question)	답변 (Answer)
------	-----	---------------	-------------

드	명		
A	도 메 인 정 의/ 목 적	「데이터 산업진흥 및 이용촉진에 관한 기본법」에서 데이터안심구역을 지정하여 운영하는 주된 목적은 무엇입니까?	데이터안심구역은 누구든지 데이터를 안전하게 분석·활용할 수 있는 구역을 지정하여, 미개방 데이터, 분석 시스템 및 도구 등을 지원함으로써 데이터 이용을 활성화하기 위함입니다.
B	데 이 터 구 조/ 구 성	데이터 산업진흥법 시행령에 따라 데이터안심구역으로 지정될 수 있는 가상 공간은 무엇을 활용하여 조성된 공간이어야 합니까?	데이터안심구역은 「클라우드컴퓨팅 발전 및 이용자 보호에 관한 법률」에 따른 클라우드 컴퓨팅을 활용하여 조성한 가상의 공간을 포함할 수 있습니다.
C	AI 모 델/ 임 무	「데이터 산업진흥 및 이용촉진에 관한 기본법 시행령」에 따라 데이터 전문인력 양성기관으로 지정받을 수 있는 기관의 유형은 무엇입니까?	「고등교육법」상의 학교, 데이터 관련 교육과정을 운영하는 공공기관, 정부 출연 연구기관 등이 전문인력 양성기관으로 지정될 수 있습니다.
D	품 질/ 공 정 관 리	데이터 품질인증 대상 중 '데이터 내용'이 충족해야 하는 세 가지 품질 기준은 무엇입니까?	데이터 내용에 대한 품질 기준은 <b>완전성, 유효성, 및 정확성</b> 의 세 가지 기준을 충족해야 합니다.

### 3. 공공데이터 관리 (공공데이터 관리)

유 형 코 드	유 형 명	질문 (Question)	답변 (Answer)
A	도 메 인 정 의/ 목 적	과학기술정보통신부장관이 학습용 데이터의 생산·수집·관리·유통 및 활용의 활성화를 위해 통합제공시스템을 구축.	통합제공시스템은 학습용 데이터의 통합 검색을 통한 접근성을 높이고, 학습용 데이터를 체계적으로 분류하고 관리하여 활용도와

	<b>목적</b>	관리하는 목적은 무엇입니까?	편의성을 높이기 위함입니다.
<b>B</b>	<b>데이터 구조/구성</b>	행정안전부 고시 「공공기관의 데이터베이스 표준화 지침」에서 정의하는 'DB 표준'은 어떤 네 가지 요소를 통칭하는 것입니까?	DB 표준은 데이터베이스 표준용어, 표준단어, 표준도메인, 및 데이터베이스 표준코드를 통칭하는 것을 말합니다.
<b>C</b>	<b>AI 모델/임무</b>	「데이터기반행정 활성화에 관한 법률」에 따라 공공기관이 데이터통합관리 플랫폼에 데이터를 등록할 필요가 있다고 인정하는 분야의 예시 두 가지는 무엇입니까?	주요 정책 수립이나 경제적·사회적 문제 해결을 위해 국민 의견을 수렴할 필요가 있는 분야, 또는 안전사고나 질병 등 위험 요소를 예측하고 제거 방법을 제시할 필요가 있는 분야입니다.
<b>D</b>	<b>품질/공정 관리</b>	공공기관이 공공데이터베이스 구축 및 운영 고도화 사업을 수행할 때, 정보화 사업 발주를 위한 제안요청서에 반드시 포함해야 하는 품질 관리 요구사항은 무엇입니까?	법정부 및 기관의 데이터 표준 지침 적용 여부, 데이터 값 검증 방안, 그리고 메타데이터 등록 및 현행화 방안 등을 제시해야 합니다.

#### 4. 교육 및 학교 (교육 및 학교)

유형코드	유형명	질문 (Question)	답변 (Answer)
<b>A</b>	<b>도메인 정의/목적</b>	교육부의 '교육분야 인공지능 윤리 원칙 상세 설명자료'에서 제시하는 대원칙의 핵심은 무엇입니까?	대원칙은 '사람의 성장을 지원하는 인공지능'이며, 인공지능이 인간 성장의 잠재성을 이끌어내는 방향으로 활용되어야 합니다.
	<b>데이터</b>	교육 분야의 개방 데이터에 대한 일관성 있는 제공 및 활용을 위해	교육 분야 개방표준 데이터셋 수립을 추진하고 있으며, 디지털 교수학습 통합 플랫폼 개발과 연

B	구조/ 구성	추진하고 있는 데이터셋 관련 조치는 무엇입니까?	계하여 교수·학습 데이터 표준(코드화)을 마련하고 있습니다.
C	AI 모델/ 임무	교육 분야 인공지능 윤리 원칙은 AI가 교사의 교육 업무를 대체할 수 없다고 명시하는 근본적인 이유는 무엇입니까?	AI가 활용되는 교육 환경에서도 교사와 학생 간의 <b>인간적인 소통과 협동</b> 은 교육의 핵심 요소가 되어야 하기 때문입니다.
D	품질/ 공정 관리	충청남도교육감은 생성형 인공지능 활용 교육의 역기능 방지를 위해 어떤 책무를 가집니까?	교육감은 생성형 인공지능을 활용할 때 발생할 수 있는 역기능을 방지하기 위한 대책을 마련해야 할 책무가 있습니다.

## 5. AI 이용자 보호 (AI 이용자 보호)

유형 코드	유형 명	질문 (Question)	답변 (Answer)
A	도메인 인정 의 목 적	방송통신위원회 '생성형 인공지능 서비스 이용자 보호 가이드라인'의 궁극적인 목표는 무엇입니까?	안전하고 신뢰할 수 있는 이용 환경을 마련하여 이용자의 권익을 보장하고, 생성형 AI의 올바른 사용 혜택을 모든 사회 구성원이 고루 누리도록 하는 것입니다.
B	데이터 구조/ 구성	서비스 제공자가 이용자의 입력 및 생성 데이터를 학습 데이터로 활용할 경우, 가이드라인에 따라 이용자에게 보장해야 하는 핵심적인 권리들은 무엇입니까?	서비스 제공자는 입력 및 생성 데이터를 학습 데이터로 활용할 경우, 이를 사전에 고지하고 이용자가 <b>활용에 동의하거나 거부</b> 할 수 있는 절차를 마련해야 합니다.
AI 모		이용자가 생성형 AI 산출물에 편향성이 있다고 판단했을 때, 서비스 제공자가 갖	서비스 제공자는 이용자가 편향성을 바로 신고할 수 있는 <b>직관적인 방법</b> 을 제공

C	델/임무	취야 하는 대응 시스템의 요소는 무엇입니까?	하고, 신고 내용을 처리하는 절차를 마련해야 합니다.
D	품질/공정관리	AI 기본법 시행령 초안의 투명성 의무 관련 내용에 따라, 생성형 AI가 만든 이미지 결과물에 'AI 생성물'임을 표시할 때 이용이 인정되는 기술적 방식은 무엇입니까?	이미지 품질 저하 방지를 위해 인간의 눈으로는 인식할 수 없는 <b>비가시적 워터마크</b> 를 표시하는 방식이 인정됩니다.

## 6. AI 법제 및 윤리 (AI 법제 및 윤리)

유형코드	유형명	질문 (Question)	답변 (Answer)
A	도메인정의/목적	인권 관점에서 본 AI 윤리 및 접근성 보고서와 관련하여, 정부가 지원해야 할 핵심 사업 분야는 무엇입니까?	인공지능이 인간의 존엄성 및 기본권을 존중하는 방향으로 개발·이용될 수 있도록 하는 <b>기술 또는 기준의 연구개발 및 보급 사업</b> 을 지원해야 합니다.
B	데이터구조/구성	교육 분야 인공지능 윤리 원칙에 인용된 법정부 윤리 기준에서, 데이터 관리와 관련된 10대 핵심 요건 세 가지는 무엇입니까?	데이터 관리, 책임성, 안전성 및 투명성 등이 법정부 윤리 기준의 10대 핵심 요건에 포함됩니다.
C	AI모델/임무	인공지능 기술의 안전하고 편리한 이용을 지원하기 위해 정부가 추진 할 수 있는 연구 개발 사업의 예시는 무엇입니까?	「지능정보화 기본법」에 따른 <b>비상 정지 기능</b> 을 인공지능 제품이나 서비스에서 구현하기 위한 기술 연구 지원 및 확산 사업 등을 지원할 수 있습니다.
	품질/공	AI 개발 및 활용 과정에서 발생할 수	인공지능 개발 및 활용 과정에서 책임 주체를 설정하여 피해를 최소화해야 하며, 설계 및 개

D	정 관 리	있는 피해를 최소화하기 위해 책임 소재를 어떻게 설정해야 합니까?	발자, 서비스 제공자, 사용자 간의 책임 소재를 명확히 해야 합니다.
---	-------	--------------------------------------	--

## 7. 저작권 및 법제 (저작권 및 법제)

유형 코드	유형명	질문 (Question)	답변 (Answer)
A	도메인 정의/목적	생성형 인공지능(GAI) 산출물 자체는 저작권 등록이 불가능한 근본적인 이유는 무엇입니까?	저작물은 '인간의 사상 또는 감정을 표현한 창작물'이어야 하는데, GAI 산출물은 인간의 창작적 기여가 없는 결과물이므로 저작권법상 저작물에 해당하지 않습니다.
B	데이터 구조/구성	GAI 산출물을 활용한 편집저작물이 성립되기 위해 충족되어야 하는 핵심적인 저작권법상 요건은 무엇입니까?	소재(GAI 산출물 등)의 선택, 배열 또는 구성에 작성자의 개성이 어떠한 형태로든 나타나 있어 창작성이 인정되어야 합니다.
C	AI 모델/임무	생성형 AI가 만든 이미지에 저작권 등록이 가능하려면, 제작 과정에서 인간의 창작성이 어떻게 발휘되어야 합니까?	GAI 산출물을 생성한 후, 이를 조합, 변형, 배치, 편집, 질감 추가 등의 방법을 통해 최종 이미지를 완성하는 과정에서 인간의 창작적 기여가 인정되어야 합니다.
D	품질/공정 관리	AI 생성물을 활용한 저작물 등록 시, 기존 AI 산출물에 저작권자가 추가한 편집 과정의 사례를 두 가지 제시하십시오.	GAI 산출물을 분할하여 재배치하거나, 먹물 처리 및 나무 블록화 등의 변형/배치 과정을 통해 최종 이미지를 완성할 수 있습니다.

## 8. 정보화 (정보화)

유형코드	유형명	질문 (Question)	답변 (Answer)
A	도메인정의/목적	행정안전부의 「정보화업무 처리 규정」에서 정의하는 '데이터기반행정'의 궁극적인 목표는 무엇입니까?	데이터기반행정은 데이터를 활용하여 정책 수립과 의사결정에 사용함으로써 행정을 객관적이고 과학적으로 수행하는 것입니다.
B	데이터구조/구성	「전자정부법」에 따라 구축·운영되며, 행정안전부의 「정보화업무 처리 규정」에서 정보자원의 공동 관리 및 활용을 위해 운영하는 시스템은 무엇이며, 어떤 법적 근거를 가집니까?	「전자정부법」에 따라 구축·운영되는 **범정부 EA 포털(GEAP)**이며, 행정기관 및 공공기관의 정보자원을 공동으로 등록·관리·활용하도록 합니다.
C	AI모델/임무	공공기관이 정보화 사업을 발주하기 전에 '사전 협의'를 통해 검토하고 조정해야 할 주요 사항 네 가지는 무엇입니까?	종복성, 상호 연계, 공동 이용, 그리고 <b>공공데이터 개방 및 개인정보 보호, 사이버 보안</b> 등에 대한 사항을 검토·조정해야 합니다.
D	품질/공정관리	정보화 업무 처리 규정에서 '공공데이터 품질 관리'를 정의할 때, 이용자에게 유용한 가치를 제공하기 위해 확보해야 하는 데이터의 주요 속성은 무엇입니까?	공공데이터의 <b>최신성, 정확성, 및 상호연계성을</b> 유지하여 이용자에게 유용한 가치를 제공할 수 있도록 품질을 확보하는 일련의 활동입니다.

## IV. 결론 및 AADS 프로젝트 기여

### 1. 규제와 거버넌스 QA 데이터셋의 전략적 가치

규제와 거버넌스 분야 QA 데이터셋은 AADS LLM이 단순히 데이터 과학 지식만 갖춘 것이 아니라, **법적 및 윤리적 환경** 내에서 데이터를 감사하고 관리할 수 있는 **책임성(Accountability)** 있는 AI로 거듭나도록 합니다.

이 데이터셋은 사회안전 분야 QA 구축 시 적용된 방법론과 같이, 단순한 정보 추출을 넘어, 정의, 구조, AI 모델의 기술적 선택 이유, 품질 관리의 전략적 의미를 묻는 추론 기반 질의를 포함하고 있습니다. 이를 통해 LLM은 복잡한 규제 문서를 구조적으로 이해하고 논리적으로 사고하는 능력을 기르게 됩니다.

## 2. LLM 파인튜닝의 기반 강화

규제와 거버넌스 도메인 특화 데이터셋은 LLM 파인튜닝의 전략적 자산으로서, 데이터 과학자의 작업을 지능적으로 보조할 자율 AI 에이전트 개발에 실질적인 진전을 가져올 것입니다.

마지막으로, 본 보고서에서 제시된 심층적이고 체계적인 QA 데이터셋 구축 방법론은 향후 다른 전문 분야로 확장될 수 있는 검증된 모델로서, AADS 프로젝트의 지속적인 발전에 기여할 잠재력을 지니고 있습니다.



Pebblous Makes Data Tangible

[contact@pebblous.ai](mailto:contact@pebblous.ai)