

STAR-MNIST: 수퍼포물라를 이용한 학습데이터 생성 및 기계학습 활용 예

차복^{1,2}, 이주행^{2,1}

1. 과학기술연합대학원대학교, 2. 한국전자통신연구원
{bokc, joohaeng}@etri.re.kr

STAR-MNIST: Generation the Learning Data with Superformular And Practical Usage in Deep Learning

Cha Bok^{1,2}, Joo – Haeng Lee^{2,1}
1. UST 2. ETRI

요약

딥러닝의 발전과 더불어 양질의 학습 데이터에 대한 수요와 중요성이 증대되고 있다. 본 논문에서는 MNIST처럼 가벼우면서도 다양한 기계학습의 문제에 동시에 적용할 수 있는 기하학적 형태에 대한 제어 가능한 가상학습셋인 STAR-MNIST 데이터셋을 제안한다. STAR-MNIST는 하나의 식으로 다양한 형태를 표현하는 것으로 잘 알려진 수퍼포물라(Superformular)를 이용하여 생성한다. 특히, 수퍼포물라의 다차원 인수를 제어하여 식별(classify) 및 인수추정(regression)에 동시에 적합한 데이터셋을 생성하였다. STAR-MNIST는 수퍼포물라의 특징인 매개인수 곡선의 특성을 유지하면서도 MNIST 수준의 난이도를 갖게 하기 위해서 곡선의 형상에 몇 가지 변형을 부여하였다. 실험에서는 STAR-MNIST의 생성 과정과 이를 기본적인 LeNet에 적용하였을 때의 성능 및 인수추정에 사용하는 예를 보인다.




그림 1: STAR-MNIST와 MNIST

1. 서론

딥러닝에 입문하면 일반적으로 MNIST 학습 데이터를 통해 CNN과 Classification 개념을 익히게 된다. 우리는 딥러닝 학습의 기본이 되는 식별 및 인수추정에 동시에 적합한 데이터셋을 고안하였고 잘 알려진 Superformular 공식을 이용해 기하 정보를 가지는 학습 데이터로 STAR-MNIST를 만들었다.

2. STAR-MNIST 데이터 생성

수식1인 Superformular 공식은 6개의 변수(a, b, m1, m2, n1, n2, n3)를 통해 다양한 도형을 표현할 수 있는 강력한 수식이다.

$$r(\varphi) = \left(\left| \frac{\cos\left(\frac{m_1\varphi}{4}\right)}{a} \right|^{n_2} + \left| \frac{\sin\left(\frac{m_2\varphi}{4}\right)}{b} \right|^{n_3} \right)^{-1/n_1}$$

수식 1: Superformular 공식

2.1. STAR-MNIST

STAR-MNIST는 수식2와 같이 닫힌 도형을 생성하기 위해 수퍼포물라에서 변수 n_1, n_2, n_3 과 m, φ 만 사용한다. 변수 중 a와 b를 1로 고정하고, m_1 과 m_2 를 같게 하고 변수 m는 2에서 11사이 범위의 실수 값을 사용한다. ($a = b = 1, m_1 = m_2$)

$$r(\varphi) = \left(\left(\cos\left(\frac{m\varphi}{4}\right) \right)^{n_2/2} + \left(\sin\left(\frac{m\varphi}{4}\right) \right)^{n_3/2} \right)^{-1/n_1}$$

수식 2: STAR-MNIST의 Superformular 공식

도형은 중심을 기준으로 무작위로 회전해 생성되고, 각 도형을 생성하는 변수 값을 이미지 파일 명으로 명시했다. 결과로 28x28 크기의 이미지로 총 7만개를 생성했다. 파라미터 생성은 5분, 이미지 생성에 15분이 소요된다.

각 도형의 선분 굵기는 3에서 10까지 8단계를 기본으로 생성된 후 그림2-(2)와 같이 0.0025 만큼의 랜덤 노이즈를 추가해 마치 손으로 그릴 때 생기는 필압과 같이 불규칙한 선분의 폭을 만들었다. 또한, 학습난이도와 관련해 다음 두가지 Concavity와 ConvexNegate 성질을 추가했다.

2.2. Concavity

도형의 중심으로부터 뾰족하게 나온 꼭지점과 오목하게 들어간 각 극점까지의 거리 차이를 Concavity라 정의하고 Concavity의 ArgMin, ArgMax를 구할 때 계




그림 2:(1) 변형 전 도형, (2) 선분 굽기 변형, (3) 무작위 회전 및 크기 변형, (4) ConvexNegate 음각

산 속도를 높이고 미분이 가능해 모든 극점을 알 수 있도록 수퍼포몰러의 절대값 부분을 제곱과 제곱근의 쌍으로 교체해 계산하였다. 그 결과 Concavity가 0.15~0.95값을 갖는 도형이 생성 되도록 했다.

2.3. ConvexNegate

기존 도형을 모두 감싸는 다각형(convex hull)을 만들어 원 도형을 감산하여 각 도형의 음각 이미지를 생성하는 방식인 ConvexNegate를 추가 하였다. 그림 2-(4)인 음각 도형 이미지를 전체 학습 데이터의 20%로 구성하여 학습 난이도를 향상 시켰다.

3. 실험


3.1 학습 설계

전체 학습에 사용된 데이터는 MNIST와 동일 60,000개, 검증에 사용된 데이터는 10,000개, Batch 크기는 720, 최적화 기법은 ADAM을 사용하였다.


STAR-MNIST 데이터셋은 전체 7만개 중 기본 도형 80% 음각 도형 20%를 혼합해 학습하였다. 개발 환경은 Mathematica를 사용했고 GPU로 연산 하였다. 학

	Input	image
1	ConvolutionLayer	array (size: 1×28×28)
2	Ramp	array (size: 20×24×24)
3	PoolingLayer	array (size: 20×12×12)
4	ConvolutionLayer	array (size: 50×8×8)
5	Ramp	array (size: 50×8×8)
6	PoolingLayer	array (size: 50×4×4)
7	FlattenLayer	vector (size: 800)
8	LinearLayer	vector (size: 500)
9	Ramp	vector (size: 500)
10	LinearLayer	vector (size: 100)
11	SoftmaxLayer	vector (size: 10)
	Output	class

(1)



(2)



(3)

그림 4:LeNet네트워크 구조와 분류 학습 결과

습에 사용된 네트워크는 잘 알려진 LeNet을 사용해 분류(Classification)와 인자 추정(Regression) 학습을 실험 했다.

3.2 실험 결과

그림 3에서 STAR-MNIST와 MNIST 데이터셋에 대하여 분류 학습에 사용된 LeNet구조와 학습 결과 정확도에 도달하는 추이와 Loss 값의 감소 속도를 비교한 그래프를 볼 수 있다. STAR-MNIST의 정확도는 99.67%로 MNIST의 99%와 비슷했고 학습 초반에 정확도가 높아지는 속도가 MNIST보다 STAR-MNIST가 느리게 학습 됨을 확인 할 수 있다. 그림 4-(3)에서 Loss 그래프 감소 속도를 비교하면 MNIST보다 STAR-MNIST가 학습은 천천히 되지만 정확도는 더 높다. 이를 통해 MNIST보다 학습 난이도가 높고 정확도는 더 높은 학습 데이터임을 알 수 있다.




그림 5: 인자 추정 학습을 위해 변형한 LeNet 네트워크 구조와 Concavity 인자 추정 학습 결과

STAR-MNIST 데이터 셋을 이용해 LeNet 네트워크 구조를 변형4-(1) Concavity 인자 추정 학습 결과 그림 4-(2)와 같이 이미지로부터 Concavity를 잘 찾아내는 것을 확인 할 수 있었다.

4. 결론

STAR-MNIST는 수퍼포몰라의 매개변수 곡선의 특성을 유지하면서 도형의 기하학적인 정보를 가지고 있다. 실험에서 증명한 Concavity외에 다양한 도형의 기하정보를 응용 및 생성 가능하기에 인수적 기하 도형 학습 데이터 생성 관점에서 활용 가능성이 높다. 심층 신경망 학습을 통해 도형의 기하 정보를 분류, 추정 학습 하는데 좋은 데이터 셋으로 활용되기를 기대한다.

* 포스터 발표논문

* 본 연구는 “고령 사회에 대응하기 위한 실환경 휴먼케어 로봇 기술 개발” (2017-0-00162) 및 “딥러닝용 가상 학습셋 생성 기술을 이용한 자동점수 시스템 개발” (2018-DD-RD-0097) 과제의 지원으로 수행되었음.

참고문헌

- [1] Johan Gielis, A generic geometric transformation that unifies a wide range of natural and abstract shapes, *American Journal of Botany*, 90(3): 333-338, 2003.
- [2] Y.LeCun, L.Bottou, Y.Bengio and Haffner P, Gradient-Based Learning Applied to Document Recognition, *Proceedings of the IEEE*, 86, 2278-2324, November 1998.